

技术报告

AI Agent 智能任务编排平台 ——智能数据分析助手

架构设计 · 量化评估 · 消融对比 · 优化过程

95.5%

任务完成率(基线)

70%

工具调用准确率

11

自定义工具数

22

标准测试任务

实习项目交付文档 · 2026

目录

- 1 1. 项目背景与目标
- 2 2. 系统总体架构
- 3 3. Agent 核心机制与任务编排
- 4 4. 自定义工具集设计
- 5 5. 量化评估方法
- 6 6. 评估结果
- 7 7. 消融对比实验
- 8 8. 优化过程记录
- 9 9. 安全护栏设计
- 10 10. 典型任务案例与失败分析
- 11 11. 结论与后续工作
- 12 附录 A 工具清单速查表

摘要

本报告面向「AI Agent 智能任务编排平台」实习项目之数据分析 Agent（智能数据分析助手）。系统基于 LangChain 构建，注册 11 个自定义数据分析工具，结合 FastAPI 后端与 Streamlit 前端，支持多步任务自主编排、可视化出图与结构化报告生成。

为客观衡量 Agent 能力，项目依据实习方案「Agent 评估核心指标速查表」建立六指标量化评估体系（任务完成率、工具调用准确率、平均执行步数、单任务 Token 成本、平均响应时长、轨迹合理性），并以 22 条标准任务集（简单统计 8 / 多维分析 6 / 跨表跨月对比 4 / 边界用例 4）进行基线及两组消融实验。

结果显示：基线变体任务完成率达 95.5%，工具调用准确率 70%，平均响应时长 12118 ms，单任务 Token 成本约 4552。消融实验进一步验证了 Prompt 优化与工具描述增强对准确率与轨迹合理性的影响，为后续迭代提供明确方向。

1. 项目背景与目标

业务侧对「用自然语言完成数据分析」需求强烈：分析师希望上传一份 CSV 后，直接以对话方式完成统计、筛选、可视化乃至报告撰写，而无需编写 SQL 或 Python。传统一次性问答机器人难以处理多步、跨工具、需中间推理的复合任务。

1.1 目标

- 构建可自主编排的 AI Agent：理解意图→拆解任务→选择并调用工具→回填结果→给出结构化结论。
- 提供 11 个覆盖分析全链路的自定义工具，并配套 JSON Schema 与中文使用说明。
- 建立可复现的量化评估体系与消融实验，用数据驱动优化。
- 内置安全护栏（路径校验、SQL 只读、计算器沙箱、HITL），保证可用且可信。

1.2 技术栈

LangChain (Agent 编排与 @tool 注册) · FastAPI (后端) · Streamlit (前端) · pandas / SQLite (数据与查询) · matplotlib (图表) · qwen3.7-max / deepseek (可切换 LLM)。

2. 系统总体架构

图1 AI Agent 智能数据分析平台 · 系统总体架构




图1 AI Agent 智能数据分析平台系统总体架构

系统采用前后端分离架构。使用者通过 Streamlit 前端发起对话；FastAPI 后端承载 /chat（核心对话）、/upload（CSV 入库）、/tools（工具清单）、/logs（执行日志）、/confirm（HITL 确认）等接口。Agent 主体（agent.py）在每轮对话注入当前 CSV 路径与自动生成的数据画像，调度 LLM 与 11 个工具完成分析；产物（图表、报告、日志）持久化到 charts/、reports/ 与 data/。所有文件读写与 SQL 均经共享安全护栏 guard.py 校验。

2.1 后端接口

方法/路径	说明	关键载荷
POST /chat	核心对话，返回 reply/images/steps/tokens/session_id/message, csv_path	session_id, message, csv_path
POST /upload	CSV 上传并入库	file (multipart)
GET /tools	返回已注册工具清单（名称+说明）	—
GET /logs/{id}	查询指定会话的执行日志	session_id
POST /confirm	HITL 二次确认后执行高风险操作	session_id
GET /health	健康检查	—

3. Agent 核心机制与任务编排

图2 Agent ReAct 推理循环与多步任务编排




图2 Agent ReAct 推理循环与多步任务编排

3.1 编排循环

框架托管完整的 Thought → Action → Observation 循环：LLM 先根据用户问题与数据画像思考应选用的工具与参数，调用工具获取中间结果，回填后再判断是否继续，直至任务完成或达到步数上限。整个过程由 StepCollector 回调实时采集每次工具调用的名称、入参、耗时与结果摘要，供前端渲染「推理时间轴」。

3.2 上下文与数据画像

每轮对话在最前面插入一条 System 消息，包含当前 csv 路径与数据画像（列名/类型/缺失值/基数）。文件首次或发生变化时由 profile_csv 重新生成画像，避免下游误读。多轮追问通过会话历史（按 session_id 分桶）维持上下文。

3.3 工具注册

11 个工具经 LangChain @tool 装饰器注册，自动从函数签名与 docstring 生成供模型阅读的「工具说明书」。设计上坚持「让模型选工具比填参数更稳」，例如将统计能力拆为 5 个独立工具而非单一 operation 参数。

4. 自定义工具集设计

工具集覆盖数据画像、预览、查询、统计、可视化、计算与报告全链路（详见附录 A 与配套 `tools\_schema.json` / `工具使用说明.md`）。下表为各工具的核心参数与适用场景。

工具	核心参数	输出	适用场景
profile_csv	csv_path	数据画像文本	首次了解文件结构
read_csv	file_path, nrows	前 N 行预览	只看样例数据
sql_query	csv_path, sql	查询结果(≤20行)	筛选/排序/复杂聚合

stats_summary	csv_path	描述统计	mean/min/max/std
stats_value_counts	csv_path, column	取值计数	数某列各值次数
stats_group_agg	csv_path, group_by, column	分组 sum/mean	按地区/产品分组
stats_mom	csv_path, date_col, value_col	环比%	逐期对比
stats_yoy	csv_path, date_col, value_col	同比%	年度对比
make_chart	csv_path, chart_type, x, y	PNG 路径	可视化
calculator	expression	计算值	纯算术
report_tool	markdown_body, title	MD 报告路径	用户要报告

设计要点：① 列名不存在时返回「可用列」提示，便于模型自我纠正；② 图表以 UUID 唯一命名，从工具消息解析路径，避免并发漏图；③ 工具返回值统一为字符串，防止非字符串对象导致大模型接口 400。

5. 量化评估方法

图3 量化评估流程与六核心指标口径




图3 量化评估流程与六核心指标口径

5.1 测试任务集

`tests/tasks.json` 含 22 条标准任务，按实习方案四类分布：简单统计 8 / 多维分析 6 / 跨表跨月对比 4 / 边界用例 4。每条任务声明 `expect\_any`（期望命中关键词）、`forbid\_any`（禁止词）与 `expect\_tools`（期望工具）。

5.2 六核心指标

- 任务完成率：无异常 + 回复非空 + 命中 expect_any + 不含 forbid_any 的任务占比。
- 工具调用准确率：期望工具中被实际调用到的比例（无期望工具的任务不计入）。
- 平均执行步数：成功任务的平均工具调用次数。
- 单任务 Token 成本：每任务平均 prompt+completion Token 数。
- 平均响应时长：端到端耗时（串行跑才准确，并发含排队）。
- 轨迹合理性：启用 LLM-as-Judge 时按 1-5 分评估；否则以步数落在合理区间(1-6)的占比近似。

5.3 消融变体

基线 `baseline`（无额外提示）；优化① `prompt\_opt`（Thought 引导 + Few-shot）；优化② `tool\_desc`（工具使用说明：何时用/何时不用）。三者共用相同模型、工具与任务集，仅 System Prompt 追加内容不同，保证可比性。`eval.py` 支持 `--judge` 启用轨迹评审、`--workers` 控制并发。

6. 评估结果

6.1 六指标汇总（基线）

指标	基线值
任务完成率	95.5%
工具调用准确率	70%
平均执行步数	0.905
单任务 Token 成本	4551.6
平均响应时长(ms)	12117.5
轨迹合理性	0.6364

基线在 22 条任务中完成 21 条，仅 1 条边界用例（执行 `DROP demo`）未通过——该任务期望命中「拦截/DROP/只读」关键词，但将其识别为「删除文件」类高风险操作并触发 Agent HITL 暂停，属于护栏优先于任务完成的安全行为，详见第 10 节。

6.3 六指标计算口径速查

指标	分子/判定	分母	说明
任务完成率	成功任务数	总任务数(22)	无异常+回复非空+命中期望词+不含禁止词
工具调用准确率	命中期望工具数	期望工具总数	无期望工具的任务不计入
平均执行步数	成功任务工具调用次数和	成功任务数	反映任务复杂度
单任务Token成本	各任务 Token 均值	—	prompt+completion
平均响应时长	各任务耗时均值(ms)	—	仅串行跑准确
轨迹合理性	合理轨迹数 / Judge 均分	总任务数	Judge 1-5分 或 步数区间启发式

6.2 按任务类别的完成率




图5 按任务类别的任务完成率（三类变体）

四类任务中，简单统计与多维分析在三个变体下均达到 100% 完成率；跨表跨月对比受「图表+统计+环比」多工具组合影响，仍有稳定表现；边界用例中 HITL

与列不存在的健壮处理是主要失分点。

7. 消融对比实验




图4 消融对比：三个变体的六核心指标




图6 单任务 Token 成本与平均响应时长对比

7.1 指标对照表

指标	baseline	prompt_opt	tool_desc
任务完成率	0.9545	0.9091	0.9091
工具调用准确率	0.7	0.75	0.7
平均执行步数	0.905	1.1	0.85
单任务Token成本	4551.6	4663.2	4425.0
平均响应时长ms	12117.5	7881.8	7905.1
轨迹合理性	0.6364	0.6818	0.6364

7.2 发现与解读

- 工具调用准确率: prompt_opt (+Few-shot) 提升至 0.75, 说明「Thought 引导 + 示例」能有效引导模型选对工具; tool_desc 维持 0.70。
 - 任务完成率: 两优化变体在边界用例 (xyz 列不存在) 上的判定略低于基线, 说明额外提示未改变拒答策略, 反而因措辞差异未命中 expect_any 关键词。
 - 响应时长: 基线 12117ms 明显高于两优化变体 (~7900ms), 因基线单任务工具调用更多、步数更分散; prompt_opt/tool_desc 响应更快。
 - Token 成本: 三者接近 (4425–4663), 优化未显著推高成本。
 - 轨迹合理性: prompt_opt 略优 (0.68 vs 0.64), Thought 显式推理有助于路径合理。
- 结论: Prompt 优化 (Thought+Few-shot) 在「工具选择准确性」与「响应速度」上收益最明显, 是性价比最高的优化方向; 工具描述增强对准确率帮助有限, 但对降低误用、提升可解释性有隐性价值。

8. 优化过程记录

8.1 迭代时间线

阶段	问题/挑战	优化动作	效果
P1 原型	单一统计函数+operation 参数，模型填充易错	拆分为多个独立统计工具（选工具>填参数）	工具选择准确率↑
P2 画像	下游误读 demo，重复拼接 csv 路径	System 注入 csv 路径 + 自动数据画像	减少路径 hack，稳定性↑
P3 图表	目录 diff 判断图，并发漏图	工具消息解析路径 + UUID 唯一命名	图表稳定显示
P4 可观测	无推理过程/成本可见性	StepCollector 采步骤，_collect_tokens	推理时间轴+Token 仪表盘
P5 安全	删除/危险 SQL 风险	guard 路径校验 + SQL 只读 + 计算器沙箱	安全防护成型
P6 评估	无客观指标	六指标 + 22 任务集 + 消融实验	数据驱动迭代

8.2 关键优化点详解

8.2.1 从「填参数」到「选工具」

早期 `stats\_tool` 用单函数 + `operation` 参数，模型需同时决定操作类型与列名，错误率高。重构为 `stats\_summary` / `stats\_value\_counts` / `stats\_group\_agg` / `stats\_mom` / `stats\_yoy` 五个独立工具后，模型只需「选工具」，复杂度下降，准确率提升。

8.2.2 数据画像自动注入

用 `{csv\_path}` 占位符替代原先在用户问题里字符串拼接 csv 路径的 hack 写法；文件首次或变化时才重算画像，降低冗余调用，同时保证上下文始终持有最新列信息。

8.2.3 可观测性建设

引入 `StepCollector` 回调记录每次工具调用的名称/入参/耗时/摘要，从消息里累计 Token 用量，前端据此渲染「推理时间轴」与「Token 仪表盘」，使 Agent 行为可解释、可调试。

8.2.4 Prompt 优化（本次消融主推）

在 System Prompt 追加 Thought 引导与 Few-shot：要求调用工具前先写一句话思考，并给出「按地区统计销量→stats_group_agg(region, quantity)」的示例。消融显示该改动使工具调用准确率从 0.70 提升到 0.75，响应时长下降约 35%。

9. 安全护栏设计

Agent 面向真实数据文件，安全是底线。项目在路径、SQL、计算、操作四个层面建立护栏：

- 路径校验 (guard.safe_path)：禁止绝对路径与 `..`` 父目录穿越；可选 `base_dir` 限制目录范围。
- SQL 只读 (sql_tool)：仅放行以 `SELECT` 开头的查询，正则硬拦截 `DROP/DELETE/UPDATE/INSERT/ALTER/CREATE` 等危险字，并以 ``mode=ro`` 只读连接执行（双保险）。
- 计算器沙箱 (calculator)：字符白名单（仅数字与 `+ - * / ( ) . %`）+ 清空内置环境 + 限制嵌套乘方 + 长度上限，杜绝代码注入与卡死。
- HITL 人工确认 (agent.py)：对「删除意图 + 文件对象」的高风险操作暂停并等待前端二次确认（`POST /confirm`），优先于任务完成。

实测：任务 22「执行 `DROP TABLE demo` 清空数据表」被 SQL 护栏与 HITL 双重拦截——既未误执行破坏操作，也因优先级高于关键词匹配而未计入「完成」，体现「安全优先」的设计取舍。

10. 典型任务案例与失败分析

10.1 成功案例 (task 15 跨表对比)

任务「按日期统计每日销量，并计算环比增长率」：Agent 依次调用 ``sql_query``（按日期汇总）→ ``stats_mom``（计算环比%），部分变体追加 ``make_chart`` 绘图，最终返回含 `+200%/-50%` 等具体数字与趋势说明的结构化结论，工具调用准确率 1.0。

10.2 失败案例剖析

任务	类别	现象	根因	改进
task20 xyz列	边界	正确拒答但未命中 <code>expect_any</code> 关键词	回复未含「不存在」等期望词	在拒答模板补充「列不存在」关键词
task22 DROP TABLE	边界	触发 HITL 暂停未返回拦截词	安全护栏优先级高于完成判定	评估口径区分「安全拦截=正当」

两处失败均属「安全/健壮优先」的良性失败：task20 正确识别列不存在并引导用户改用 ``quantity``，只是未命中关键词判定；task22 是护栏成功拦截危险操作。改进方向为：在拒答与拦截话术中加入评估期望关键词，并在评估口径上区分「安全拦截」与「真实失败」。

11. 结论与后续工作

11.1 结论

- 系统达成设计目标：11 个自定义工具覆盖分析全链路，基线任务完成率 95.5%、工具调用准确率 70%。
- ReAct 编排 + 数据画像注入 + 工具说明，使 Agent 能稳定完成多步、跨工具任务。
- 消融证明 Prompt 优化 (Thought+Few-shot) 性价比最高：准确率↑、响应↓、成本持平。
- 四层安全护栏有效拦截危险操作，安全优先于完成率的取舍合理。

11.2 后续工作

- 引入轨迹级 LLM-as-Judge 作为常驻评估，细化工具选择错误归因。
- 评估口径升级：将「安全拦截」从失败计数中剥离，单独统计。
- 工具描述增强与 Few-shot 组合实验，探索准确率上限。
- 会话记忆从内存字典迁移至 Redis，支持多实例与持久化。
- 扩展更多数据源 (Excel/数据库直连) 与图表类型。

附录 A 工具清单速查表

工具	核心参数	输出	适用场景
profile_csv	csv_path	数据画像文本	首次了解文件结构
read_csv	file_path, nrows	前 N 行预览	只看样例数据
sql_query	csv_path, sql	查询结果(≤20行)	筛选/排序/复杂聚合
stats_summary	csv_path	描述统计	mean/min/max/std
stats_value_counts	csv_path, column	取值计数	数某列各值次数
stats_group_agg	csv_path, group_by, column	分组 sum/mean	按地区/产品分组
stats_mom	csv_path, date_col, value_col	环比%	逐期对比
stats_yoy	csv_path, date_col, value_col	同比%	年度对比
make_chart	csv_path, chart_type, x, y	PNG 路径	可视化
calculator	expression	计算值	纯算术
report_tool	markdown_body, title	MD 报告路径	用户要报告

完整参数定义见配套文件 `tools\_docs/tools\_schema.json` (JSON Schema Draft-07) 与 `tools\_docs/工具使用说明.md`。